

Clasificación Espectral de Objetos Astronómicos mediante Aprendizaje Automático: Aplicación al Dataset SDSS DR17

Mariana Castellanos
Departamento de Electrónica
Pontificia Universidad Javeriana, Bogotá, Colombia
{mariana-castellanos}@javeriana.edu.co

Resumen—Este trabajo presenta el diseño de un sistema de clasificación automática de objetos astronómicos utilizando datos espectroscópicos del Sloan Digital Sky Survey (SDSS). El objetivo principal consiste en desarrollar un clasificador multiclase capaz de distinguir entre cuásares, galaxias y estrellas a partir de características fotométricas y espectroscópicas. Se detalla el marco teórico fundamentado en la astrofísica de observación, la descripción del dataset SDSS Data Release 17, y un plan de trabajo estructurado en tres fases: análisis estadístico exploratorio, diseño de clasificadores en MATLAB y validación comparativa de modelos. La metodología propuesta enfatiza una validación rigurosa que trasciende la simple exactitud (accuracy), incorporando métricas apropiadas para problemas de clasificación multiclase potencialmente desbalanceados.

Index Terms—Clasificación espectral, Sloan Digital Sky Survey, aprendizaje automático, fotometría astronómica, catálogo estelar, MATLAB.

I. OBJETIVO GENERAL

Diseñar e implementar un clasificador multiclase, utilizando técnicas de aprendizaje automático en MATLAB, que permita distinguir entre cuásares, galaxias y estrellas a partir de datos espectroscópicos y fotométricos del Sloan Digital Sky Survey (SDSS) Data Release 17. El sistema deberá someterse a un protocolo de validación estadísticamente riguroso que evalúe múltiples métricas de desempeño, reconociendo que la efectividad del clasificador depende de un conjunto integral de indicadores y no únicamente de la exactitud global (accuracy).

II. OBJETIVOS ESPECÍFICOS

- OE1.** Realizar un análisis estadístico exploratorio comprehensivo del dataset SDSS DR17 para determinar: (i) el grado de desbalance entre las clases de objetos astronómicos, (ii) las características fotométricas y espectroscópicas con mayor poder discriminativo, y (iii) las relaciones estadísticamente significativas entre las variables predictoras y la clase objetivo.
- OE2.** Diseñar e implementar en MATLAB tres arquitecturas de clasificación distintas, seleccionadas estratégicamente con base en los hallazgos del análisis estadístico preliminar, considerando la naturaleza multiclase y las características del espacio de características.
- OE3.** Establecer un marco de validación robusto para la evaluación comparativa de los clasificadores desarrollados,

utilizando métricas apropiadas para problemas multiclase (precisión, recall, F1-score, matriz de confusión), y determinar cuál modelo presenta el mejor compromiso entre generalización e interpretabilidad.

III. MARCO TEÓRICO

III-A. El Proyecto Sloan Digital Sky Survey (SDSS)

El Sloan Digital Sky Survey (SDSS) constituye uno de los proyectos de cartografía astronómica más ambiciosos y citados de la historia contemporánea. Iniciado en el año 2000, este consorcio internacional ha revolucionado nuestra comprensión del universo mediante la creación de mapas tridimensionales detallados que trascienden las simples imágenes fotográficas del cielo. A diferencia de los atlas astronómicos tradicionales, el SDSS cuantifica sistemáticamente las distancias cosmológicas de los objetos celestes y captura sus “huellas digitales” espectrales, permitiendo el estudio de la estructura a gran escala del cosmos, la evolución de las galaxias y la distribución de la materia oscura [1].

El proyecto se ha desarrollado en etapas sucesivas de creciente sofisticación:

- **SDSS-I y II (2000–2008):** Fase de mapeo inicial del universo local y extensión galáctica mediante el programa SEGUE (Sloan Extension for Galactic Understanding and Exploration).
- **SDSS-III y IV (2008–2020):** Implementación de estudios de oscilaciones para la medición precisa de distancias cosmológicas, y mapeo integral de galaxias cercanas mediante el proyecto MaNGA (Mapping Nearby Galaxies at Apache Point Observatory).
- **SDSS-V (2020–presente):** Transición hacia observaciones robóticas en ambos hemisferios celestes, operando tres mapeadores especializados: el Local Volume Mapper (para galaxias del vecindario cósmico), el Milky Way Mapper (para la estructura de nuestra galaxia) y el Black Hole Mapper (para el estudio de agujeros negros supermasivos).

El dataset objeto de estudio en este trabajo corresponde al **SDSS Data Release 17 (DR17)**, publicado en 2021, que representa la culminación de la cuarta fase del proyecto. Este conjunto de datos, de acceso público y dominio abierto, comprende aproximadamente 100,000 observaciones

espectroscópicas de objetos celestes previamente clasificados por expertos astrónomos, lo que lo convierte en un recurso excepcional para el desarrollo y validación de algoritmos de clasificación automática.

III-B. Fundamentos Físicos de la Clasificación Espectral

La discriminación entre diferentes tipos de objetos astronómicos fundamenta su viabilidad en principios físicos bien establecidos de la astrofísica de observación. Cada clase de objeto celeste presenta una *firma espectral característica* determinada por procesos físicos intrínsecos que generan patrones distintivos en la distribución espectral de su radiación electromagnética.

III-B1. Mecanismos de Emisión y Firmas Espectrales: La clasificación espectral se sustenta en las siguientes diferencias físicas fundamentales:

- **Estrellas:** Emiten radiación térmica que se aproxima a la de un cuerpo negro. Su espectro presenta líneas de absorción características. La temperatura superficial determina el pico de emisión y su Redshift es casi cero.
- **Galaxias:** Constituyen sistemas complejos compuestos por poblaciones estelares de diferentes edades y metalicidades. Su espectro integrado resulta de la superposición de múltiples componentes estelares, presentando un continuo más suave que las estrellas individuales, con líneas de absorción promediadas.
- **Cuásares (QSOs):** Núcleos de galaxias activas alimentados por agujeros negros supermasivos en proceso de acreción. Se caracterizan por líneas de emisión anchas y desplazamientos al rojo considerables ($z > 0,1$) debido a su ubicación en el universo distante.

III-B2. Sistema Fotométrico SDSS y Colores Espectrales:

El SDSS implementa un sistema fotométrico de cinco bandas espectrales (u, g, r, i, z) que actúan como una *espectroscopía de resolución baja* (fotometría de banda ancha). Este diseño permite capturar la forma general del espectro de energía distribuida (SED, *Spectral Energy Distribution*) de los objetos mediante la medición de magnitudes en longitudes de onda específicas:

- Filtro u (ultravioleta, $\lambda \approx 355$ nm): Sensibles a la presencia de estrellas jóvenes y calientes, y a la emisión de cuásares.
- Filtro g (verde/azul, $\lambda \approx 469$ nm): Transición entre región ultravioleta y óptica.
- Filtro r (rojo, $\lambda \approx 617$ nm): Banda de referencia principal para fotometría SDSS.
- Filtros i y z (infrarrojo cercano, $\lambda \approx 748$ nm y 893 nm): Capturan la cola roja del espectro, útil para objetos de alto redshift.

Las *colores fotométricos*, definidos como diferencias de magnitud entre pares de filtros adyacentes (por ejemplo, $u - g, g - r, r - i, i - z$), constituyen indicadores discriminativos particularmente poderosos. En el diagrama color-color, las estrellas se distribuyen a lo largo de una secuencia diagonal bien definida (secuencia principal), mientras que las galaxias

presentan colores más rojos debido a la dominancia de poblaciones estelares evolucionadas, y los cuásares aparecen como objetos extremadamente azules (bajos valores de $u - g$) o con colores incompatibles con la secuencia estelar local.

Adicionalmente, el parámetro de *redshift* (z) proporciona información cosmológica crucial: las estrellas del halo galáctico presentan $z \approx 0$, mientras que galaxias y cuásares exhiben $z > 0$ con distribuciones características que reflejan su historia de formación y evolución.

III-C. Descripción del Dataset y Variables

El dataset SDSS DR17 objeto de estudio comprende 17 variables descriptivas por observación, que pueden clasificarse en cuatro categorías funcionales: identificadores únicos, coordenadas celestes, mediciones fotométricas/espectroscópicas, y metadatos instrumentales. La Tabla I presenta la descripción detallada de cada variable.

Las variables de mayor relevancia para la clasificación automática son las cinco magnitudes fotométricas (u, g, r, i, z) y el redshift (*redshift*), dado que encapsulan la información física fundamental sobre la naturaleza de los objetos astronómicos. Las variables de identificación y metadatos, aunque esenciales para la trazabilidad y el control de calidad, típicamente no se emplean como predictores directos en modelos de clasificación.

IV. JUSTIFICACIÓN

La comprensión sistemática del universo representa uno de los grandes imperativos del conocimiento científico contemporáneo. En este contexto, la capacidad de distinguir automáticamente entre diferentes tipos de objetos celestes—estrellas, galaxias y cuásares—constituye una herramienta fundamental tanto para la investigación astrofísica de vanguardia como para la educación científica y la divulgación astronómica.

La clasificación espectral automatizada mediante técnicas de aprendizaje automático ofrece beneficios significativos en múltiples dimensiones:

- **Eficiencia en el procesamiento de grandes volúmenes de datos:** Los proyectos de sondeo astronómico modernos generan catálogos que comprenden cientos de millones de objetos. Los métodos automáticos permiten procesar estos volúmenes de manera escalable, liberando recursos humanos para tareas de análisis científico de mayor complejidad.
- **Objetividad y reproducibilidad:** La clasificación manual, aunque realizada por expertos, puede presentar variabilidad inter-observador. Los algoritmos entrenados proporcionan criterios consistentes y cuantificables, facilitando la reproducibilidad de los estudios astronómicos.
- **Detección de objetos inusuales:** Los clasificadores automatizados pueden identificar objetos que se desvían de los patrones establecidos, potencialmente revelando fenómenos astrofísicos desconocidos o transitorios de interés científico excepcional.
- **Aplicaciones educativas y de divulgación:** La implementación de estos sistemas en entornos académicos permite

Cuadro I: Descripción de Variables del Dataset SDSS DR17

Variable	Descripción	Tipo	Contexto Técnico
obj_ID	Identificador único del objeto en el catálogo de imágenes CAS	Identificador	Referencia primaria para localización en la base de datos SDSS
alpha (α)	Ascensión recta en el equinoccio J2000	Coordenada celeste	Longitud celeste en el sistema de coordenadas ecuatoriales (0–24h o 0–360°)
delta (δ)	Declinación en el equinoccio J2000	Coordenada celeste	Latitud celeste (-90° a +90°)
u	Magnitud en filtro ultravioleta ($\lambda \approx 355$ nm)	Fotometría	Sistema fotométrico SDSS; magnitudes menores indican objetos más brillantes
g	Magnitud en filtro verde ($\lambda \approx 469$ nm)	Fotometría	Banda óptica azul-verde
r	Magnitud en filtro rojo ($\lambda \approx 617$ nm)	Fotometría	Banda óptica roja; referencia principal para estudios SDSS
i	Magnitud en infrarrojo cercano ($\lambda \approx 748$ nm)	Fotometría	Primer canal del infrarrojo cercano
z	Magnitud en infrarrojo ($\lambda \approx 893$ nm)	Fotometría	Segundo canal IR; límite del sistema óptico-IR del SDSS
run_ID	Número de ejecución del escaneo	Metadato	Identifica una noche específica de observación
rerun_ID	Número de reprocesamiento	Metadato	Versión del pipeline de procesamiento de imágenes aplicado
cam_col	Columna de cámara (1–6)	Metadato	Identifica la línea de escaneo; el SDSS utiliza 6 columnas CCD
field_ID	Número de campo	Metadato	Identificador de campo individual dentro de una ejecución
spec_obj_ID	ID único para objetos espectroscópicos	Identificador crítico	Dos observaciones con igual spec_obj_ID comparten necesariamente la misma clase
class	Clase del objeto (star/galaxy/quasar)	Variable objetivo	Clasificación espectral experta que sirve como <i>ground truth</i>
redshift	Corrimiento al rojo (z)	Física	Indica expansión cosmológica; $z \approx 0$ para estrellas locales, $z > 0$ para objetos extragalácticos
plate	ID de la placa espectroscópica	Metadato	Identificador de placa metálica donde se montan las fibras ópticas
MJD	Fecha juliana modificada	Temporal	Indica el momento de observación (días desde el 17 de noviembre de 1858)
fiber_ID	ID de fibra óptica (1–640)	Metadato instrumental	Identifica la fibra que dirigió la luz al plano focal del espectrógrafo

a estudiantes de ingeniería y ciencias exactas interactuar con datos reales de investigación astronómica de primer nivel, cerrando la brecha entre la formación técnica y la práctica científica contemporánea.

V. AVANCES Y PLAN DE TRABAJO

El desarrollo del proyecto se estructura en tres fases secuenciales, correspondientes a los objetivos específicos establecidos. A continuación se detallan los avances alcanzados y las actividades planificadas.

V-A. Fase 1: Análisis Estadístico Exploratorio (OE1)

En esta fase se han iniciado las siguientes actividades de caracterización del dataset:

Act 1: Verificación del balance de clases: Se ha realizado el conteo inicial de frecuencias para las tres categorías (star, galaxy, quasar) con el fin de detectar posible desbalance

que pudiera afectar el entrenamiento de los clasificadores. Se planifica el cálculo de métricas de desbalanceo.

Act 2: Detección de anomalías en calidad de datos: Se está implementando un protocolo de detección de valores faltantes (codificados típicamente como NaN o valores sentinela como -9999 en astronomía), identificación de registros duplicados mediante la variable spec_obj_ID, y detección de *outliers* univariados y multivariados en el espacio de magnitudes fotométricas.

Act 3: Análisis univariado y bivariado: Se han generado estadísticas descriptivas (media, mediana, desviación estándar, asimetría, curtosis) para cada variable numérica. Se planifica la construcción de histogramas por clase, diagramas de caja (*boxplots*) para identificar solapamientos entre distribuciones, y análisis de correlación entre las cinco bandas fotométricas.

V-B. Fase 2: Diseño de Clasificadores (OE2)

Con base en los hallazgos del análisis exploratorio, se seleccionarán tres arquitecturas de clasificación distintas considerando:

- **Clasificador basado en distancias**
- **Clasificador probabilístico**

La implementación se realizará utilizando el *Statistics and Machine Learning Toolbox* de MATLAB.

V-C. Fase 3: Validación y Selección del Modelo Óptimo (OE3)

Se establecerá un protocolo de validación que trascienda la exactitud global (*accuracy*), dado que esta métrica puede resultar engañosa en presencia de desbalance de clases. El marco de evaluación incluirá:

- **Validación cruzada estratificada:** División del dataset en k pliegues (típicamente $k = 5$ o $k = 10$) manteniendo la proporción de clases en cada partición.
- **Métricas de desempeño multiclase:**
 - Precisión (*precision*), y puntuación F1 (*F1-score*) por clase.
 - Matriz de confusión normalizada para visualizar patrones de error entre pares de clases
- **Consideraciones especiales de agrupación:** Dado que la variable `spec_obj_ID` indica que múltiples observaciones pueden corresponder al mismo objeto físico, se implementará un esquema de validación por grupos (*grouped cross-validation*) para evitar *data leakage* entre conjuntos de entrenamiento y prueba.

VI. CONSIDERACIONES DE VALIDACIÓN Y MÉTRICAS DE EVALUACIÓN

Es fundamental enfatizar que la efectividad del clasificador no puede reducirse a un único valor de exactitud global. En problemas de clasificación astronómica, donde las clases pueden presentar distribuciones desiguales (típicamente, galaxias y estrellas son más frecuentes que cuásares), una métrica global puede ocultar un rendimiento deficiente en la clase minoritaria.

Por tanto, el protocolo de validación adoptará un enfoque multidimensional:

1. **Evaluación por clase:** Reporte individual de precisión, recall y F1-score para estrellas, galaxias y cuásares, permitiendo identificar qué tipos de objetos presentan mayor confusión.
2. **Análisis de errores:** Inspección sistemática de la matriz de confusión para identificar si el clasificador confunde particularmente ciertos pares de clases (por ejemplo, estrellas versus cuásares de bajo redshift, que pueden presentar colores similares).
3. **Estabilidad estadística:** Reporte de intervalos de confianza para las métricas obtenidos mediante validación cruzada repetida, cuantificando la variabilidad del desempeño del modelo.

VII. RESULTADOS DEL ANÁLISIS ESTADÍSTICO EXPLORATORIO

A continuación se presentan los resultados obtenidos en cada actividad de la Fase 1, junto con su interpretación en el contexto del diseño del clasificador.

VII-1. Balance de Clases (Act. 1): El conteo de frecuencias revela un desbalance moderado pero estadísticamente relevante: las galaxias constituyen la clase mayoritaria con 59.445 observaciones (59,4 % del total), mientras que las estrellas y los cuásares representan el 21,6 % (21.594) y el 19,0 % (18.961), respectivamente, sobre un total de 100.000 registros (Fig. 1).




Figura 1: Distribución de clases en el dataset SDSS DR17. Las galaxias representan el 59,4 % del total, generando un desbalance que debe considerarse en el diseño del clasificador.

Este desbalance tiene implicaciones directas sobre el diseño del clasificador: un modelo optimizado únicamente sobre la exactitud global (*accuracy*) podría sesgarse hacia la clase GALAXY, ya que asignar esa etiqueta a todos los objetos produciría trivialmente un 59,4 % de acierto. Por esta razón, el F1-score por clase y el *recall* para QSO y STAR serán los indicadores primarios de desempeño en la Fase 3. Adicionalmente, se evaluará el uso de pesos de clase ponderados y validación cruzada estratificada para mitigar el efecto del desbalance.

VII-2. Calidad de Datos (Act. 2): La inspección de valores centinela (−9999, convención estándar en catálogos astronómicos para datos no disponibles) revela una contaminación mínima: un único registro afectado en cada uno de los filtros u , g y z , sin ninguna afección en los filtros r , i ni en el *redshift*. No se detectaron valores NaN adicionales, y no se encontraron registros duplicados mediante la variable `spec_obj_ID`.

Aunque tres observaciones con valores centinela son anecdóticas frente a 100.000 registros, su presencia en los filtros u , g y z —precisamente las bandas con mayor utilidad discriminativa para cuásares y estrellas calientes— distorsiona la escala de los histogramas de esas bandas (Fig. 2). Estos tres registros serán eliminados antes del entrenamiento, documentando la estrategia para garantizar la reproducibilidad del protocolo.

VII-3. Análisis Univariado y Bivariado (Act. 3):

VII-3a. Distribuciones por clase.: Los histogramas de las seis variables predictoras (Fig. 2) revelan que los filtros r e i presentan distribuciones superpuestas entre las tres clases en el rango 14–25 mag, lo que implica que ninguna magnitud fotométrica individual es suficiente para separar las clases. Las galaxias muestran una distribución extendida hacia magnitudes más débiles (valores numéricos más altos), consistente con su naturaleza como objetos extendidos y difusos. El *redshift* es la variable con mayor poder discriminativo individual: las estrellas se concentran en $z \approx 0$, las galaxias presentan una distribución hasta $z \approx 1,3$, y los cúasares alcanzan valores de $z > 5$.




Figura 2: Histogramas de las seis variables predictoras por clase. Los filtros u , g y z muestran distribuciones distorsionadas por los valores centinela. El *redshift* exhibe la mayor separación entre clases.

VII-3b. Redshift por clase.: El diagrama de caja de la Fig. 3 confirma y cuantifica la separación entre clases. Las estrellas presentan un rango intercuartílico (IQR) prácticamente nulo alrededor de $z = 0$, coherente con su pertenencia a la Vía Láctea. Las galaxias muestran una mediana cercana a 0,45 con $\text{IQR} \approx [0,0, 0,65]$, mientras que los cúasares exhiben una mediana alrededor de 1,6 con $\text{IQR} \approx [1,0, 3,9]$ y numerosos valores atípicos por encima de $z = 4$. Estos valores atípicos no son errores de medición: son cúasares reales en el universo distante.

La zona de solapamiento entre GALAXY y QSO en el rango $z \approx 0,8\text{--}1,3$ representa la región de mayor ambigüedad, y constituye la principal fuente de error esperada en la matriz de confusión de la Fase 3.




Figura 3: Diagrama de caja del *redshift* por clase. Las estrellas se concentran en $z \approx 0$; los cúasares alcanzan valores superiores a $z = 6$. La zona de solapamiento GALAXY–QSO en $z \approx 0,8\text{--}1,3$ anticipa la principal fuente de errores de clasificación.

VII-3c. Correlación entre variables fotométricas.: La matriz de correlación (Fig. 4) expone dos bloques de alta correlación independientes entre sí. El primero está formado por los filtros u , g y z , con correlaciones de $\rho \geq 0,998$; el segundo lo forman r e i , con $\rho = 0,963$. Entre ambos bloques, las correlaciones son prácticamente nulas ($\rho \approx 0,05\text{--}0,06$).




Figura 4: Matriz de correlación entre variables fotométricas y *redshift*. Se identifican dos bloques de alta correlación independientes: $\{u, g, z\}$ y $\{r, i\}$.

Esta estructura refleja que los filtros u , g y z capturan procesos físicos dominados por la misma región espectral (emisión UV e infrarrojo extremo), mientras que r e i cubren la franja óptica-roja. Incluir las cinco magnitudes brutas en el clasificador introduciría redundancia severa. Se recomienda construir los colores diferenciales ($u - g$, $g - r$, $r - i$, $i - z$) como variables de entrada, ya que capturan la forma de la SED con menor colinealidad. El *redshift* muestra correlaciones

moderadas únicamente con r ($\rho = 0,43$) e i ($\rho = 0,49$), aportando información sustancialmente independiente.

VII-3d. Diagrama color-color. El diagrama color-color (Fig. 5) representa cada objeto en el plano definido por los colores $(u - g)$ en el eje X y $(g - r)$ en el eje Y. Recordando que un “color” fotométrico es la diferencia entre las magnitudes medidas en dos filtros adyacentes, este diagrama codifica la *forma local del espectro* en dos franjas contiguas, con independencia del brillo absoluto del objeto. Dos objetos físicamente idénticos pero a distancias distintas ocuparán exactamente el mismo punto en este plano.




Figura 5: Diagrama color-color $(u - g)$ vs. $(g - r)$. Los ejes han sido acotados al rango donde se concentra el 99 % de los datos para excluir los registros con valores centinela. Las estrellas forman la secuencia principal diagonal; los cuásares presentan exceso ultravioleta (valores menores de $u - g$); las galaxias se dispersan hacia colores más rojos.

Las estrellas forman una secuencia diagonal compacta —la *secuencia principal estelar*— con $(u - g) \in [-1, 2]$ y $(g - r) \in [-0,5, 0,5]$, reflejo de que la emisión térmica estelar sigue una relación física bien definida entre filtros adyacentes. Los cuásares se concentran en la región de $(u - g)$ negativos o moderados y $(g - r)$ cercano a cero, por debajo de la secuencia estelar, debido al exceso de emisión ultravioleta no térmica de los núcleos activos. Las galaxias presentan la mayor dispersión, extendiéndose hacia valores positivos en ambos ejes, reflejo de su naturaleza como sistemas con poblaciones estelares de distintas edades. El solapamiento parcial entre las tres clases confirma que el espacio color-color no es suficiente por sí solo para una clasificación robusta.

VII-A. Conclusiones de la Fase 1 e Implicaciones para la Fase 2

El análisis estadístico exploratorio permite extraer las siguientes conclusiones, ordenadas por su relevancia para el diseño del clasificador en la Fase 2:

1. **El redshift es el predictor dominante.** Es la única variable que, por sí sola, separa limpiamente las tres clases:

estrellas en $z \approx 0$, galaxias en $z \in [0, 1,3]$ y cuásares en $z \in [0,5, 7]$. Su inclusión como predictor mejorará sustancialmente el desempeño de cualquier clasificador. Sin embargo, dado que en astronomía observacional el *redshift* espectroscópico requiere tiempo de telescopio adicional, podría ser de interés evaluar también un clasificador fotométrico puro (sin *redshift*) para cuantificar la degradación de desempeño.

2. **Las magnitudes fotométricas brutas son altamente redundantes.** Los dos bloques de correlación $\{u, g, z\}$ ($\rho \geq 0,998$) y $\{r, i\}$ ($\rho = 0,963$) implican que incluir las cinco magnitudes como predictores independientes inflaría artificialmente la dimensionalidad sin aportar información nueva. Se recomienda sustituirlas por los cuatro colores diferenciales $(u - g, g - r, r - i, i - z)$ antes de entrenar los modelos.
3. **El desbalance de clases exige estrategias de mitigación.** La razón de 59,4 % GALAXY frente a ~ 20 % de cada clase minoritaria impone el uso de validación cruzada estratificada y métricas por clase (F1-score, *recall*) como criterios de selección del modelo. Los clasificadores basados en probabilidad (p.ej., Naïve Bayes o regresión logística multinomial) permiten además ajustar umbrales de decisión por clase, lo que los hace especialmente adecuados para este escenario.
4. **La zona de mayor dificultad es GALAXY-QSO en $z \approx 0,8-1,3$.** En esta región los colores fotométricos se solapan y el *redshift* no proporciona separación clara. Los errores de clasificación se concentrarán aquí; el análisis de la matriz de confusión de la Fase 3 deberá prestar atención específica a este par de clases.
5. **Limpieza previa al entrenamiento.** Los tres registros con valores centinela en u, g y z deben eliminarse antes de construir los modelos. Su presencia es anecdótica en volumen pero puede introducir ruido en una región crítica del espacio de características para la separación de cuásares.

VIII. FASE 2: DISEÑO DE CLASIFICADORES

Con base en las conclusiones del análisis exploratorio (Fase 1), se implementaron tres arquitecturas de clasificación distintas: k-Nearest Neighbors (k-NN), Regresión Logística Multinomial y Random Forest. La selección de estos modelos responde a una diversificación deliberada del espacio de hipótesis: desde un clasificador no paramétrico local (k-NN), pasando por un modelo lineal probabilístico (RL), hasta un ensamble no lineal (RF). Esta triada garantiza que al menos una arquitectura sea adecuada para cada régimen del espacio de características identificado en la Fase 1.

El preprocesamiento previo al entrenamiento siguió estrictamente las cinco conclusiones críticas de la Fase 1: (i) eliminación de tres registros con valores centinela —9999 en filtros u, g y z ; (ii) transformación de cinco magnitudes brutas a cuatro colores diferenciales $(u - g, g - r, r - i, i - z)$ para eliminar redundancia; (iii) inclusión del *redshift* como predictor dominante; (iv) partición estratificada 80/20 para

mantener proporciones de clase; y (v) estandarización z-score con estadísticas calculadas exclusivamente sobre el conjunto de entrenamiento para evitar data leakage.

VIII-A. Clasificador 1: *k*-Nearest Neighbors (*k*-NN)

VIII-A1. Justificación y configuración: El *k*-NN se fundamenta en la hipótesis de continuidad del espacio de características: objetos con propiedades fotométricas similares comparten la misma naturaleza física. Esta suposición es particularmente adecuada porque el diagrama color-color (Fig. 5) revela que las estrellas forman una secuencia diagonal compacta, mientras que cuásares y galaxias ocupan regiones diferenciadas aunque con solapamiento parcial. El *k*-NN explota esta estructura local sin imponer una forma funcional global, lo cual es esencial dado que la zona de solapamiento GALAXY-QSO en $z \approx 0,8-1,3$ genera una frontera compleja que modelos paramétricos rígidos difícilmente capturan.

La sensibilidad a la maldición de la dimensionalidad se mitiga mediante la reducción a cinco dimensiones totales (cuatro colores + redshift), un espacio de baja dimensionalidad donde el *k*-NN conserva su efectividad. Se exploraron $k \in \{5, 7, 9, 11, 15, 21\}$, distancia Euclidiana estandarizada, pesos de vecinos uniformes e inversos a la distancia, y pesos de clase empíricos e inversos a frecuencia. La métrica de selección fue F1-macro para evitar sesgo hacia la clase mayoritaria.

VIII-A2. Resultados: La mejor configuración encontrada fue: $k = 7$, pesos de vecinos inversos a la distancia, y pesos de clase empíricos (sin compensación), con F1-macro de $0,9515 \pm 0,0018$ en validación cruzada de 5 pliegues. La evaluación en el conjunto de prueba independiente arrojó los resultados de la Tabla II.

Cuadro II: Métricas por clase — *k*-NN óptimo (conjunto de prueba)

Clase	Precisión	Recall	F1-Score
GALAXY	0.9689	0.9630	0.9659
QSO	0.9522	0.9296	0.9408
STAR	0.9366	0.9717	0.9539
MACRO	—	—	0.9535

VIII-A3. Análisis: El *k*-NN alcanza un desempeño sólido con F1-macro de 0.9535. La clase STAR presenta el recall más alto (0.9717), consistente con su concentración en $z \approx 0$ que facilita la identificación por vecindad en el espacio de características. Los cuásares, aunque con el recall más bajo (0.9296), mantienen una precisión aceptable (0.9522), indicando que cuando el modelo predice QSO, acierta en la mayoría de los casos. La matriz de confusión (Fig. 6) revela que la principal fuente de error es la confusión GALAXY-QSO en la región de redshift intermedio, tal como se anticipó en la Fase 1.

El hecho de que los pesos de clase empíricos superen a los inversos sugiere que el espacio de características ya proporciona separación suficiente; forzar una compensación artificial no mejora el compromiso global precision-recall. Los pesos inversos a la distancia resultaron mejores que los uniformes, indicando que en regiones de baja densidad

(como la nube de cuásares), los vecinos más cercanos aportan información más relevante.

k-NN Óptimo ($k=7$, pesos=inverse)
F1-macro = 0.9535

True Class	GALAXY	96.3%	1.5%	2.2%	96.3%	3.7%
	QSO	6.6%	93.0%	0.5%	93.0%	7.0%
	STAR	2.8%	0.1%	97.2%	97.2%	2.8%
		GALAXY	QSO	STAR		
		Predicted Class				

Figura 6: Matriz de confusión normalizada por fila — *k*-NN óptimo ($k = 7$, pesos inversos a la distancia, pesos de clase empíricos). La diagonal dominante refleja el buen desempeño general; la confusión principal ocurre en el par GALAXY-QSO.

El *k*-NN con $k = 7$ y pesos inversos a la distancia presenta una diagonal dominante que refleja el buen desempeño general (F1-macro 0.9535). La clase STAR alcanza el recall más alto (97.2%), confirmando que la secuencia estelar compacta en el espacio color-color facilita su identificación por vecindad. La principal fuente de error es la confusión GALAXY→QSO (6.6% de los cuásares reales clasificados como galaxias) y QSO→GALAXY (1.5% de las galaxias reales clasificados como cuásares). Estos errores se concentran en la región $z \approx 0,8-1,3$ donde colores y redshift no proporcionan separación nítida, tal como se anticipó en la Fase 1. Notablemente, la confusión STAR→QSO es prácticamente nula (0.1%), indicando que el redshift $z \approx 0$ de las estrellas las aísla efectivamente de la nube de cuásares.

VIII-B. Clasificador 2: Regresión Logística Multinomial

VIII-B1. Justificación y configuración: La regresión logística multinomial modela la probabilidad posterior $P(C_k|\mathbf{x})$ mediante una función softmax sobre una combinación lineal de predictores. A diferencia del *k*-NN, impone fronteras de decisión lineales y proporciona estimaciones de probabilidad calibradas que facilitan el ajuste posterior de umbrales. Esta propiedad resulta valiosa para implementar *cost-sensitive learning* de manera natural: al modificar los priors, se puede forzar al clasificador a ser más conservador con las clases minoritarias sin alterar la arquitectura.

Adicionalmente, ofrece interpretabilidad astrofísica directa: cada coeficiente indica la contribución log-odds de una variable a la probabilidad de pertenecer a una clase específica. Se utilizó regularización L2 (Ridge) con $\lambda \in \{0, 0,01, 0,1, 1, 10\}$, solver L-BFGS, y los tres esquemas de pesos de clase.

VIII-B2. *Resultados:* La mejor configuración fue: $\lambda = 0$ (sin regularización), pesos empíricos, con F1-macro de $0,9422 \pm 0,0020$ en validación cruzada. Los resultados en prueba se presentan en la Tabla III.

Cuadro III: Métricas por clase — Regresión Logística óptima (conjunto de prueba)

Clase	Precisión	Recall	F1-Score
GALAXY	0.9569	0.9585	0.9577
QSO	0.8966	0.9059	0.9012
STAR	0.9768	0.9634	0.9700
MACRO	—	—	0.9430

VIII-B3. *Análisis:* El valor óptimo $\lambda = 0$ indica que, con aproximadamente 80,000 observaciones y solo cinco predictores estandarizados, el riesgo de sobreajuste es mínimo. La relación observaciones/parámetros es suficientemente elevada como para que los 15 coeficientes (5 predictores $\times$ 3 clases) se estimen de forma estable sin penalización adicional. Esto no implica que las fronteras sean simples, sino que el modelo lineal no tiene capacidad excesiva para memorizar ruido dado el volumen de datos.

El esquema empírico superó a uniforme e inverso, sugiriendo que el desbalance, aunque estadísticamente significativo, no degrada el desempeño en términos de F1-macro. La alta capacidad discriminativa del espacio de características — particularmente el redshift que separa limpiamente estrellas locales de objetos extragalácticos— hace que la compensación artificial no sea necesaria.

Comparado con k-NN, la regresión logística presenta un F1-macro ligeramente inferior (0.9430 vs. 0.9535). Esto indica que las fronteras de decisión reales en el espacio de características no son completamente lineales; la zona de solapamiento GALAXY-QSO en $z \approx 0,8-1,3$ requiere flexibilidad que un modelo lineal no puede proporcionar. El recall de QSO es particularmente afectado (0.9059 vs. 0.9296 en k-NN), confirmando que esta clase, con distribución más dispersa y solapamiento con galaxias, beneficia de fronteras no lineales.




Figura 7: Matriz de confusión normalizada por fila — Regresión Logística óptima ($\lambda = 0$, pesos empíricos). La confusión GALAXY-QSO es más pronunciada que en k-NN, reflejando la limitación de fronteras lineales en la región de solapamiento.

La regresión logística muestra una estructura de errores más pronunciada que k-NN, consistente con su menor F1-macro (0.9430). La confusión GALAXY→QSO asciende al 9.4 % —el error más alto entre todos los modelos— confirmando que la frontera lineal no puede capturar adecuadamente la región de solapamiento en redshift intermedio. Recíprocamente, QSO→GALAXY es del 3.3 %, indicando que el modelo lineal “empuja” cuásares de bajo redshift hacia la clase mayoritaria. La clase STAR mantiene recall aceptable (96.3 %), beneficiándose de la separación lineal que el redshift proporciona en $z \approx 0$. La casi inexistencia de confusión STAR↔QSO (0.1 % en ambos sentidos) valida que, aunque lineal, el modelo sí explota la información de redshift cuando esta es discriminativa.

VIII-C. Clasificador 3: Random Forest

VIII-C1. *Justificación y configuración:* Random Forest construye múltiples árboles de decisión entrenados sobre subconjuntos bootstrap y subespacios aleatorios de predictores. La predicción final se obtiene por votación mayoritaria. Esta arquitectura presenta tres ventajas fundamentales: (i) captura interacciones no lineales mediante fronteras ortogonales por tramos, esenciales para la zona crítica GALAXY-QSO; (ii) reduce la varianza sin incrementar el sesgo, confiriendo robustez frente a valores atípicos astrofísicos reales (cuásares con $z > 4$); y (iii) proporciona medidas de importancia de variables para validar la contribución relativa de predictores.

Se fijaron 100 árboles, crecimiento sin límite de profundidad, y criterio Gini. Se variaron: mínimo de muestras por hoja {1, 5}, número de variables por división {2, 'all'}, y pesos de clase {uniforme, inverso}. Esta reducción estratégica limitó la búsqueda a 8 configuraciones (40 entrenamientos), manteniendo la exploración de los hiperparámetros que interactúan directamente con las características del dataset.

VIII-C2. *Resultados:* La mejor configuración fue: mínimo de muestras por hoja = 1, 2 variables por división, pesos

uniformes, con F1-macro de $0,9727 \pm 0,0009$ en validación cruzada. La evaluación en prueba se presenta en la Tabla IV.

Cuadro IV: Métricas por clase — Random Forest óptimo (conjunto de prueba)

Clase	Precisión	Recall	F1-Score
GALAXY	0.9843	0.9766	0.9805
QSO	0.9342	0.9507	0.9424
STAR	0.9940	1.0000	0.9970
MACRO	—	—	0.9733

VIII-C3. Análisis: Random Forest supera consistentemente a ambos competidores, alcanzando F1-macro de 0.9733. La mejora más significativa se observa en STAR (recall perfecto de 1.0000), indicando que el ensamble captura exhaustivamente la estructura de la secuencia estelar en el espacio de colores. Los cuásares también mejoran respecto a k-NN (recall 0.9507 vs. 0.9296), beneficiándose de la capacidad del modelo para particionar recursivamente la región problemática de redshift intermedio.

El hecho de que el mínimo de hoja = 1 sea óptimo indica que el ensamble maneja efectivamente el ruido: aunque árboles individuales pueden sobreajustar, el promedio de 100 árboles sobre subconjuntos bootstrap estabiliza la predicción. Las 2 variables por división (frente a 'all') generan diversidad suficiente para evitar que todos los árboles dependan críticamente del redshift, forzando a considerar combinaciones de colores que capturan matices de la SED.

Los pesos uniformes superaron a inversos, lo cual es notable: a diferencia de k-NN y RL donde empírico ganó, aquí uniforme (que fuerza igual probabilidad a priori a las tres clases) es mejor. Esto sugiere que el mecanismo de votación mayoritaria del ensamble ya maneja implícitamente el desbalance cuando los árboles son diversos; forzar una compensación explícita introduce sesgo innecesario.




Figura 8: Matriz de confusión normalizada — Random Forest óptimo (MinLeaf=1, NumVars=2, pesos uniformes). Panel superior: normalización por fila (recall). Panel inferior: normalización por columna (precisión). La diagonal dominante y el recall perfecto de STAR confirman la superioridad del modelo.

Random Forest exhibe la matriz más diagonal de los tres modelos, con F1-macro 0.9733. El recall de STAR es perfecto (100.0 %), indicando que el ensamble captura exhaustivamente la estructura de la secuencia estelar sin excepciones. Los cuásares mejoran significativamente respecto a ambos competidores: recall 95.1 % vs. 93.0 % (k-NN) y 90.6 % (RL). La confusión GALAXY→QSO se reduce al 4.9 %, la mitad que en RL, demostrando que las fronteras por tramos del ensamble particionan efectivamente la región problemática. La confusión QSO→GALAXY es solo 2.1 %, indicando alta precisión en la identificación de cuásares. El panel inferior muestra precisión por columna: 98.4 % para GALAXY, 93.4 % para QSO y 99.4 % para STAR. La menor precisión de QSO (93.4 %) refleja que algunas galaxias de la región de solapamiento son clasificadas como cuásares, un error científicamente menos grave que el inverso en contextos de sondeo.

VIII-D. Comparativa de modelos y selección preliminar

La Tabla V resume los resultados de los tres clasificadores.

Cuadro V: Comparativa de clasificadores (F1-macro en conjunto de prueba)

Modelo	F1-macro	F1 GALAXY	F1 QSO	F1 STAR
k-NN	0.9535	0.9659	0.9408	0.9539
Regresión Logística	0.9430	0.9577	0.9012	0.9700
Random Forest	0.9733	0.9805	0.9424	0.9970

Random Forest emerge como el modelo superior en todos los indicadores. La ventaja sobre k-NN (0.9733 vs. 0.9535) se concentra principalmente en STAR y QSO, confirmando que las fronteras no lineales y la capacidad de capturar interacciones entre predictores son cruciales para este problema. La regresión logística, aunque interpretable y computacionalmente eficiente, queda en tercer lugar debido a su incapacidad para modelar la frontera curva GALAXY-QSO.

Un hallazgo transversal a los tres modelos es que los esquemas de pesos más agresivos (inverso a frecuencia) no mejoran el F1-macro. Esto indica que el espacio de características construido (colores + redshift) ya contiene información suficiente para separar las clases, y que el desbalance, aunque presente, no es el factor limitante del desempeño.

IX. FASE 3: VALIDACIÓN Y SELECCIÓN DEL MODELO ÓPTIMO

La Fase 3 se centra en la validación comparativa rigurosa de los tres modelos desarrollados en la Fase 2 (k-NN, Regresión Logística y Random Forest), con el objetivo de determinar cuál presenta el mejor compromiso entre desempeño predictivo, estabilidad estadística e interpretabilidad astrofísica. A continuación se presenta el análisis detallado de los cinco puntos de esta fase.

IX-A. Punto 1: Análisis de Estabilidad Estadística

Se cuantificó la variabilidad del desempeño de cada modelo mediante validación cruzada estratificada de 5 pliegues, repetida 10 veces con semillas aleatorias diferentes (del 1 al 10). A

diferencia de la Fase 2, donde se utilizó una única semilla fija (`rng(42)`), esta aproximación permite obtener intervalos de confianza robustos para el F1-macro y determinar no solo qué modelo tiene mejor desempeño promedio, sino también mayor estabilidad estadística.

Los resultados obtenidos se resumen en la Tabla VI.

Cuadro VI: Resultados de estabilidad estadística (CV repetida, 10 repeticiones $\times$ 5 pliegues)

Modelo	F1-macro	Media	Std	IC 95 %
k-NN ($k = 7$)		0.9513	0.0016	[0.95, 0.95]
Regresión Logística		0.9422	0.0017	[0.94, 0.94]
Random Forest		0.9727	0.0013	[0.97, 0.97]




Figura 9: IC para cada modelo

Análisis: Los tres modelos presentan intervalos de confianza de magnitudes muy similares entre sí, siendo todos estrechos (rango de aproximadamente 0.0005). Esto indica que ningún modelo exhibe una variabilidad significativamente mayor que los demás. En términos de estabilidad, todos los modelos son robustos frente a cambios en la semilla aleatoria, como se evidencia en la Figura de evolución del F1-macro por repetición, donde ningún modelo muestra fluctuaciones significativas entre semillas.




Figura 10: Estabilidad de modelos por semilla

Random Forest mantiene consistentemente el mayor F1-macro promedio (0.9727), con la menor desviación estándar (0.0013), lo que confirma su superioridad tanto en desempeño como en estabilidad. La Regresión Logística, aunque estable, presenta el menor F1-macro (0.9422), consistente con su incapacidad para modelar fronteras no lineales. El k-NN ocupa una posición intermedia con F1-macro de 0.9513.

IX-B. Punto 2: Diagnóstico de Errores Sistemáticos

Se realizó una inspección sistemática de las matrices de confusión de los tres modelos en el conjunto de prueba, con énfasis en la zona crítica GALAXY-QSO en redshift $z \approx 0.8-1.3$, identificada en la Fase 1 como la región de mayor ambigüedad.

Cuadro VII: Resumen de errores por par de clases (conjunto de prueba, en %)

Par de Confusión	k-NN	Reg. Log.	Rand. Forest
GALAXY $\rightarrow$ QSO	1.50	3.33	2.14
QSO $\rightarrow$ GALAXY	6.57	9.36	4.88
GALAXY $\rightarrow$ STAR	2.24	0.82	0.20
STAR $\rightarrow$ GALAXY	2.76	3.66	0.00
QSO $\rightarrow$ STAR	0.50	0.05	0.05
STAR $\rightarrow$ QSO	0.08	0.00	0.00

Errores en la zona crítica $z \in [0.8, 1.3]$: En esta región se encontraron 858 galaxias reales y 805 cuásares reales. Las tasas de error GALAXY $\rightarrow$ QSO fueron: k-NN 8.51 % (73/858), Regresión Logística 29.95 % (257/858) y Random Forest 12.71 % (109/858). Para QSO $\rightarrow$ GALAXY: k-NN 9.94 % (80/805), Regresión Logística 7.83 % (63/805) y Random Forest 5.34 % (43/805).




Figura 11: Diagnóstico de Errores Sistemáticos

Análisis: En todos los modelos persiste un pequeño porcentaje de error cuando el clasificador selecciona un cuásar como galaxia, pero el error no es tan significativo de forma inversa. Todos los clasificadores distinguen bastante bien entre estrellas y cuásares; Random Forest, en particular, logra una separación perfecta entre estas clases (0 % de confusión en ambos sentidos), lo cual es coherente con el dominio del redshift como predictor discriminativo y la capacidad del ensemble para explotar esta separación.

En la zona crítica, los errores se concentran en redshift pequeño (dentro del rango 0.8–1.3), coincidiendo con la predicción de la Fase 1. Además, se observa que los errores no se distribuyen uniformemente a lo largo del espacio color-color ($u - g$), sino que están concentrados en valores aproximados entre 0 y 5 en los tres modelos. Dado que los tres clasificadores

presentan el mismo patrón de errores, esto sugiere que dicho patrón es intrínseco a la naturaleza de los datos y no una malicia particular de ningún clasificador.

Respecto al redshift $z \approx 0$ (región de estrellas), sorprendentemente k-NN y Regresión Logística clasifican mal varias estrellas (2.83 % y 3.66 %, respectivamente), mientras que Random Forest no comete ningún error (0.00 %). Esto es completamente coherente con el análisis previo sobre el papel dominante del redshift y la superioridad de Random Forest para capturar esta estructura.

IX-C. Punto 3: Importancia de Variables (Random Forest)

Se analizó la importancia de los predictores en el Random Forest óptimo mediante la métrica de Reducción Media de Impureza (MDI, Mean Decrease in Impurity), con el objetivo de validar la hipótesis de la Fase 1 sobre el dominio del redshift.

Cuadro VIII: Importancia MDI de predictores en Random Forest óptimo

Predictor	Importancia (%)
$u - g$	8.29
$g - r$	11.62
$r - i$	12.90
$i - z$	3.17
redshift	64.02
Suma colores	35.98




Figura 12: Importancia MDI

Análisis: El redshift es efectivamente el predictor dominante con 64.02 % de importancia relativa, validando la hipótesis de la Fase 1. Los colores diferenciales aportan información complementaria sustancial (35.98 % en conjunto), siendo $r - i$ (12.90 %) y $g - r$ (11.62 %) los más relevantes, mientras que $i - z$ (3.17 %) aporta la menor contribución.

El análisis One-vs-All revela patrones diferenciados por clase:




Figura 13: Importancia de predictores por clase (One vs All)

- **GALAXY vs. OTRAS:** El redshift aporta 45.75 %, siendo los colores $r - i$ (24.91 %) y $g - r$ (18.95 %) particularmente importantes para separar galaxias.
- **QSO vs. OTRAS:** El redshift alcanza 56.16 %, con $g - r$ (19.05 %) y $u - g$ (11.48 %) como colores más discriminativos para cuásares.
- **STAR vs. OTRAS:** El redshift domina absolutamente con 85.75 %, mientras que los colores aportan mínima información (entre 1.40 % y 5.88 %). Esto confirma que la separación estelar se fundamenta casi exclusivamente en el redshift $z \approx 0$.

IX-D. Punto 4: Evaluación de Costos Asimétricos

Se evaluaron escenarios donde el costo de perder un cuásar (falso negativo en QSO) es mayor que el de una falsa alarma, dado el mayor valor científico de los cuásares distantes. Se ajustaron umbrales de decisión para la clase QSO en los modelos probabilísticos (Regresión Logística y Random Forest), explorando umbrales entre 0.2 y 0.6.





Figura 14: Optimización de Costos Asimétricos: Clase QSO

Resultados para Regresión Logística: El ajuste de umbrales no produjo cambios significativos en las métricas. El gráfico de optimización muestra líneas horizontales para precisión, recall y F1-macro, indicando que el modelo lineal no beneficia de la modificación de umbrales en este espacio de características.

Resultados para Random Forest: El ajuste de umbrales sí produjo mejoras observables. Con umbral 0.2, se alcanza precisión QSO de 0.8180, recall QSO de 0.9720 y F1-macro de 0.9733. El umbral óptimo seleccionado fue 0.2, logrando un recall de QSO superior al 97 % con una degradación controlada de la precisión. Esto confirma que Random Forest,

Análisis: Random Forest es el único modelo que permite una optimización significativa mediante ajuste de umbrales, reforzando su posición como clasificador preferido para escenarios con costos asimétricos. La Regresión Logística, al ser un modelo lineal con fronteras rígidas, no se beneficia de esta estrategia.



Se evaluó un modelo Random Forest entrenado únicamente con los cuatro colores diferenciales ($u - g$, $g - r$, $r - i$, $i - z$), excluyendo el redshift espectroscópico. El objetivo fue cuantificar la degradación de desempeño cuando no se dispone de redshift, situación común en sondeos fotométricos masivos.

Importancia de variables en RF fotométrico: $r - i$ (33.75 %), $g - r$ (27.32 %), $u - g$ (22.07 %) e $i - z$ (16.86 %). Sin el redshift, la importancia se distribuye más uniformemente entre los colores, siendo $r - i$ el más discriminativo.

Análisis: Como se ha mencionado a lo largo de todo el análisis, el redshift es prácticamente el clasificador en sí mismo. Era de esperarse que el clasificador se degradaría significativamente sin el redshift. La degradación del 14.0% es sustancial, afectando especialmente la clasificación de estrellas (F1 de 0.9970 a 0.7823, una caída del 21.5%) y cuásares (F1 de 0.9424 a 0.8042, caída del 14.7%). Las galaxias resultan menos afectadas (F1 de 0.9805 a 0.9235, caída del 5.8%), dado que los colores fotométricos ya capturan buena parte de su información.

La conclusión es que la clasificación fotométrica pura presenta una degradación significativa. Se recomienda obtener redshift espectroscópico para aplicaciones que requieran alta precisión. Sin embargo, con F1-macro de 0.8367, el clasificador fotométrico podría ser viable como primer filtro en sondeos masivos, priorizando la recuperación de candidatos para observación espectroscópica posterior.



Modelo	F1-GALAXY	F1-QSO	F1-STAR	F1-macro
RF con redshift	0.9805	0.9424	0.9970	0.9733
RF fotométrico puro	0.9235	0.8042	0.7823	0.8367

- La validación rigurosa de la Fase 3 confirma que **Random Forest** es el modelo óptimo para la clasificación espectral de objetos astronómicos en el dataset SDSS DR17. Esta conclusión se fundamenta en:

1. **Mayor desempeño predictivo:** F1-macro de 0.9733 en prueba, superando a k-NN (0.9535) y Regresión Logística (0.9430).
2. **Mayor estabilidad estadística:** Menor desviación estándar (0.0013) y recall perfecto para estrellas (100.0 %).
3. **Mejor manejo de la zona crítica:** Menor confusión GALAXY-QSO (4.88 % vs. 6.57 % en k-NN y 9.36 % en RL).
4. **Flexibilidad para costos asimétricos:** Permite ajuste de umbrales para maximizar el recall de cuásares.
5. **Interpretabilidad astrofísica:** Validación de la hipótesis sobre el dominio del redshift y contribución complementaria de los colores.

La selección final no se basa únicamente en el F1-macro, sino en el mejor compromiso entre desempeño predictivo,

Degradación relativa: 14.0 % en F1-macro.

estabilidad estadística, interpretabilidad astrofísica y capacidad para adaptarse a requerimientos científicos específicos, alineado con los objetivos del proyecto.

REFERENCIAS

- [1] J. Aguilar et al., “The seventeenth data release of the Sloan Digital Sky Surveys,” *Astrophysical Journal Supplements*, vol. 259, no. 2, p. 35, 2022.
- [2] N. M. Ball and R. J. Brunner, “Data mining and machine learning in astronomy,” *International Journal of Modern Physics D*, vol. 19, no. 7, pp. 1049–1106, 2010.